

以 Super Mario 為例探討強化學習的 卡關問題與改進方法

壹、前言

研究背景

- 1. Super Mario 強化學習常在特定位置反覆失敗，形成卡關。
- 2. 單純提高整體探索或加強經驗回放，未必能有效解決瓶頸問題。
- 3. 本研究以 **death zone** 找出危險區域，集中探索與學習資源來提升突破能力。

研究目標：

- 1.分析模型反覆卡關的原因
- 2.驗證區域性探索是否優於全面探索
- 3.評估關鍵經驗加權是否提升訓練效率

核心概念：將探索與學習資源集中在最常失敗的區域，而不是對整條關卡進行大幅隨機擾動。



貳、研究過程與方法

前置實驗與基準模型

- 選定 $\gamma = 0.95$ 、 $\text{learning rate} = 1.25\text{e-}4$
- 以 **QRD3QN** 訓練 **Super Mario 1-3**




記錄失敗位置




長時間卡關啟動 Boost

- 偵測訓練停滯則啟動額外探索機制
- 避免長時間陷入局部最佳解





估計危險區域

- 記錄最近死亡位置的 x 座標
- 以最近死亡位置的 **p85** 作為區域中心
- 將 **[x-200, x]** 定義為危險區域



在危險區域附近提高 epsilon




找出突破瓶頸的關鍵片段並加權

RB1：單次加權

關鍵片段被記錄時，只加權一次，避免同一批經驗被反覆放大，整體較穩定。

RB2：持續加權


訓練過程中持續提高關鍵片段被抽到的機率，突破速度較快，但後期較容易不穩定。



方法比較與結果分析


- 探索方式：Baseline / Boost only / Boost + 區域機制
- 回放策略：無改動 / RB1 / RB2
- 指標：AvgX500、通過瓶頸比例

實驗一：Boost only on/off 表現分析




Boost only 雖提升少數突破比例，但也顯著增加前段失敗。

實驗一：不同探索策略之整體表現



約在 12,000 回合突破瓶頸區，整體曲線明顯高於 baseline 與 boost only。

實驗二：不同 Replay Buffer 設計比較



討論

- **boost only** 有突破效果，但代價較大。它的 $X \geq 800$ 比例最高為 0.25%，但 $X < 400$ 比例也最高達 37.18%，明顯高於 **baseline** 的 8.56%。
- **boost + death zone** 表現較好，約在 12000 回合後突破瓶頸，後續 AvgX500 明顯高於 **baseline** 與 **boost only**。
- 加入關鍵經驗加權後，表現可再提升；其中 **RB1** 整體曲線高於原本的 **boost + death zone**，顯示適度加權關鍵片段後，能提升訓練效率與後期穩定性。

肆、結論

1. 全域探索提升不夠穩定

全域提高探索率可帶來少數突破，但整體表現波動大，無法穩定提升成效。

2. 局部探索更適合瓶頸突破


將探索集中在最常失敗的瓶頸區，能減少前段干擾，兼顧突破效果與穩定性。

3. 關鍵經驗加權有助於聚焦訓練

RB1 較穩定，整體表現較平衡；**RB2** 訓練效率較高、突破較早，但後期穩定性較差。

伍、未來展望

- 研究其他仍難以通關的關卡，例如 **8-4** 迷宮與更複雜的關卡設計。
- 將 **death zone** 從單一死亡位置統計，擴展為可動態更新的卡關區域模型，並結合死亡密度、停留時間與成功穿越率，提高判定準確性。
- 尋找能同時兼顧「提早突破瓶頸」與「後期表現穩定」的關鍵經驗加權方式



陸、參考文獻

[1] V. Mnih et al., “Human-level control through deep reinforcement learning,” Nature, 2015.
[2] W. Dabney, M. Rowland, M. G. Bellemare, and R. Munos, “Distributional Reinforcement Learning with Quantile Regression,” AAAI, 2018.
[3] W. Dabney, G. Ostrovski, and A. Barreto, “Temporally-Extended ϵ -Greedy Exploration,” arXiv:2006.01782, 2020.
[4] T. Schaul, J. Quan, I. Antonoglou, and D. Silver, “Prioritized Experience Replay,” arXiv:1511.05952, 2015